

Estadística III para Ingenieros de Sistemas

Jose Daniel Ramirez Soto 2023
jdr2162@columbia.edu

Agenda

- **anuncios varios**
- **modelos de analitica (machine learning-ML) No supervisado**
 - **PCA**
 - **K-means, Cluster jerárquico o Dendograma**
- **Practica uso de clusters y PCA en python**

Anuncios

- Resumen del curso está en el github
- La primera tarea se publicará en el github de la clase el día de mañana (24-02-2023 8:00 am). Tiene parte teórica y práctica. Fecha de entrega es el 02-03-2023 11:59 pm. (-1 punto por cada día adicional).
- Office hours, Sábados 10:30-11:30.
- (Opcional) XVIII JORNADA DE EXPOSICIÓN DE ARTÍCULOS CIENTÍFICOS, seleccionar un artículo de machine learning para presentarlo, tiempo de selección 3 de marzo.

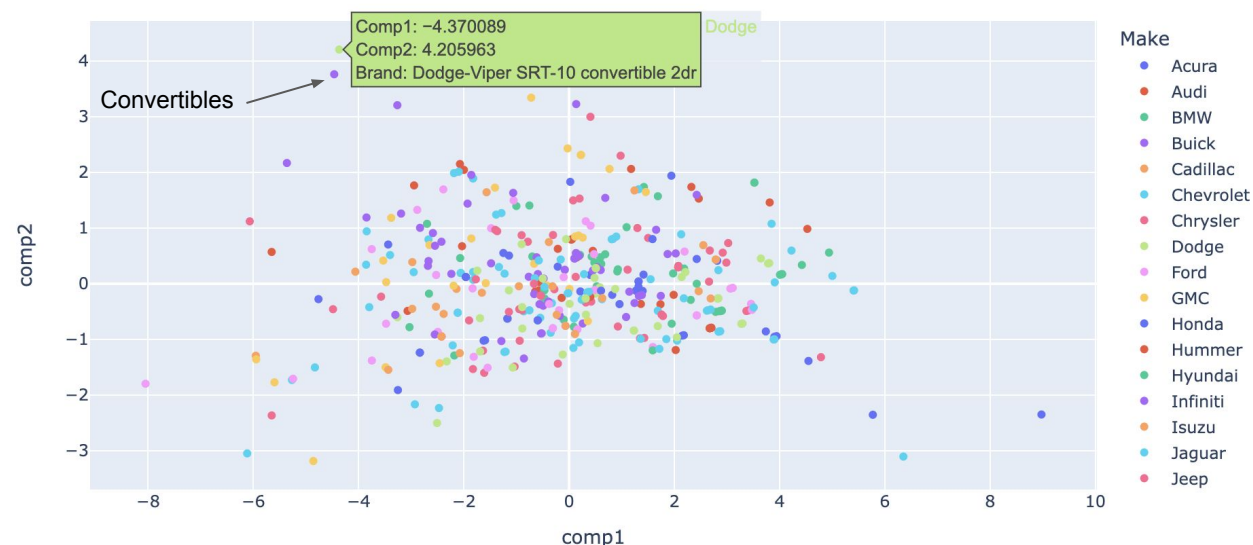
No supervisado, PCA Principal Components Analysis

PCA, es una técnica que nos permite crear combinaciones de las variables **más representativas** de una base de datos y resumir los datos un numero **menor** de dimensiones. Se utiliza para:

- **Análisis:** Encontrar las variables más importantes.
- **visualizar:** pintar datos en 2 o 3D aunque la base de datos original contenga muchas variables

Ejemplo: utilizando datos continuos del dataset de carros podemos visualizar los que son más similares.

Autos 2D with PCA



Utilizar 2 variables para resumir 8 variables continuas de los carros


No supervisado, PCA Principal Components Analysis

Proceso de PCA: Objetivo de reducir la dimensionalidad conservando la mayoría de información.


- **Standardize los datos:** Quitar la media y dividir por la desviación estándar.
- **Calcular matriz de covarianza :** Miden como 2 variables varían de forma conjunta

$$\text{Cov}(x,y) = \frac{\sum (x_i - \bar{x}) * (y_i - \bar{y})}{N}$$
- **Calcular eigenvalues :** Es la magnitud de la varianza capturada en cada componente.
- **Calcular eigenvector :** Son los nuevos ejes en los que los datos serán transformados.
- **Seleccionar K:** Cuántas dimensiones tendrá los datos transformados
- **Transformar datos :** Representación de los datos X en una menor dimensión.

X, datos originales



X*, datos transformados




No supervisado, PCA Principal Components Analysis

Proceso de PCA: Objetivo de reducir la dimensionalidad conservando la mayoría de información.


- **Standardize los datos:** Quitar la media y dividir por la desviación estándar.
- **Calcular matriz de covarianza :** Miden como 2 variables varían de forma conjunta

$$\text{Cov}(x,y) = \frac{\sum (x_i - \bar{x}) * (y_i - \bar{y})}{N}$$
- **Calcular eigenvalues :** Es la magnitud de la varianza capturada en cada componente.
- **Calcular eigenvector :** Son los nuevos ejes en los que los datos serán transformados.
- **Seleccionar K:** Cuántas dimensiones tendrá los datos transformados
- **Transformar datos :** Representación de los datos X en una menor dimensión.

X, datos originales



X*, datos transformados



No supervisado, PCA Principal Components Analysis

$$\mathbf{X} = \begin{pmatrix} 1 & -1 \\ -1 & 1 \\ 2 & 2 \\ -2 & -2 \end{pmatrix}$$

* A Course of Machine Learning <http://ciml.info/>

*<https://medium.com/analytics-vidhya/principal-component-analysis-pca-558969e63613>


No supervisado, PCA Principal Components Analysis(estandarizar)

PCA

Reducir la dimension
manteniendo la mayor

2D a 1D
varianza.

$$X = \begin{matrix} & \begin{matrix} x_1 & x_2 \end{matrix} \\ \begin{matrix} 1 \\ 2 \\ 3 \\ 4 \end{matrix} & \begin{bmatrix} 2 & -1 \\ -2 & 1 \\ 4 & 2 \\ -4 & -2 \end{bmatrix} \end{matrix}$$



1) Centrar y estandarizar

$$\mu_1 = \frac{(2 - 2 + 4 - 4)}{4} = 0 \quad \mu_2 = \frac{(-1 + 1 + 2 - 2)}{4} = 0$$

$$\sigma_{x_1}^2 = \frac{\sum_{i=1}^n (x_{1i} - \mu_1)^2}{n} \quad \sigma_{x_2}^2 = \frac{\sum_{i=1}^n (x_{2i} - \mu_2)^2}{n}$$

$$\sigma_{x_1}^2 = \frac{4 + 4 + 16 + 16}{4} = 10 \quad \sigma_{x_2}^2 = \frac{1 + 1 + 4 + 4}{4} = \frac{5}{2}$$

$$X_N = \begin{bmatrix} 0.63 & -0.63 \\ -0.63 & 0.63 \\ 1.26 & 1.26 \\ -1.26 & -1.26 \end{bmatrix}$$

$$\mu_1 = \mu_2 = 0$$

$$\sigma_1 = \sigma_2 = 1$$

No supervisado, PCA Principal Components Analysis(covarianza)

2) Calcular Matriz de covarianza

$$\Sigma = \begin{bmatrix} \sigma_{x_1}^2 & \text{cov}(x_1, x_2) \\ \text{cov}(x_2, x_1) & \sigma_{x_2}^2 \end{bmatrix} = \begin{bmatrix} 1 & 0.6 \\ 0.6 & 1 \end{bmatrix}$$

$$\text{cov}(x_1, x_2) = \sum_{i=1}^n \frac{(x_{1i} - \mu_1)(x_{2i} - \mu_2)}{N} = \frac{0.63 \times -0.63 + (-0.63 \times 0.63) + 1.26 \times 1.26 + (-1.26 \times -1.26)}{4} = \frac{2.4}{4} = 0.6$$

$$\text{cov}(x_2, x_1) = \sum_{i=1}^n \frac{(x_{2i} - \mu_2)(x_{1i} - \mu_1)}{N} = 0.6$$

$$\sigma_{x_1}^2 = \sum_{i=1}^n \frac{(x_{1i} - \mu_1)^2}{N} = \frac{0.4 + 0.4 + 1.6 + 1.6}{4} = 1$$

$$\sigma_{x_2}^2 = \sum_{i=1}^n \frac{(x_{2i} - \mu_2)^2}{N} = \frac{0.4 + 0.4 + 1.6 + 1.6}{4} = 1$$

No supervisado, PCA Principal Components Analysis(eigenvalues)

3) Hallar eigenvalues que corresponden a los

$$\det(\Sigma - \lambda I) = 0, \sum_{i=1}^0 W_i^T \Sigma W_i - \sum_{i=1}^k W_i^T \Sigma W_i$$
$$\det\left(\begin{bmatrix} 1 & 0.6 \\ 0.6 & 1 \end{bmatrix} - \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}\right) = \det\begin{pmatrix} 1-\lambda & 0.6 \\ 0.6 & 1-\lambda \end{pmatrix}$$
$$= (1-\lambda)^2 - 0.6^2$$
$$= 1 - 2\lambda + \lambda^2 - 0.36 = 0.64 - 2\lambda + \lambda^2$$
$$\lambda = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a} = \frac{\lambda = 2 \pm \sqrt{4 - 4 \times 0.64}}{2}$$
$$\lambda = \frac{2 \pm \sqrt{4 - 2.56}}{2} = \frac{2 \pm 1.2}{2} \Rightarrow \boxed{\begin{matrix} \lambda_1 = 1.6 \\ \lambda_2 = 0.4 \end{matrix}}$$

calcular eigen vector con $\lambda_1 = 1.6$ que es el valor mayor

No supervisado, PCA Principal Components Analysis(eigenvector)

$$\lambda = \frac{4}{2}$$

calculate eigenvector con $\lambda_1 = 1.6$ que es el valor mayor

$$\begin{bmatrix} 1 & 0.6 \\ 0.6 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$\textcircled{1} \quad x_1 + 0.6x_2 = 1.6x_1 \Rightarrow -0.6x_1 = -0.6x_2 \\ x_1 = x_2$$

$$\textcircled{2} \quad 0.6x_1 + x_2 = 1.6x_2 \Rightarrow 0.6x_1 - 0.6x_2 = 0 \Rightarrow x_1 = x_2$$

Si resolvemos el sistema de ecuaciones nos da $0=0$ que quiere decir infinitas soluciones. Por lo tanto cualquier vector $x_1 = x_2$ cumple esta condición

$$V_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

un test simple es validar que $\sum x V_1 = \lambda V_1$

$$\begin{bmatrix} 1 & 0.6 \\ 0.6 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = 1.6 \begin{bmatrix} 1 \\ 1 \end{bmatrix} \Rightarrow \begin{bmatrix} 1.6 \\ 1.6 \end{bmatrix} = 1.6 \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Retomando la teoría de PCA, la norma de u es 1

$$\max_u \sum_n (x_n \cdot u)^2 \quad \text{subj. to} \quad \|u\|^2 = 1$$

Por lo tanto el eigenvector V_1 debe tener una norma de 1. Como $x_1 = x_2$ entonces
 $\|V_1\| = \sqrt{x_1^2 + x_2^2} \approx 1 \Rightarrow 1 = \sqrt{2x_1^2} \Rightarrow x_1 = \sqrt{0.5} = 0.707$

Calcularemos el eigenvector z para $\lambda_2 = 0.4$

Recuerda siempre llevar el vector a ser unitario, $\|v\|=1$, $V_1 = [0.707 \ 0.707]$

No supervisado, PCA Principal Components Analysis(eigenvector)

Calcularemos el eigen vector z para $\lambda_2 = 0.4$

$$\begin{bmatrix} 1 & 0.6 \\ 0.6 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0.4 \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$\textcircled{1} \quad x_1 + 0.6x_2 = 0.4x_1 \Rightarrow 0.6x_1 + 0.6x_2 = 0 \Rightarrow x_1 = -x_2$$

$$\textcircled{2} \quad 0.6x_1 + x_2 = 0.4x_2 \Rightarrow 0.6x_1 + 0.6x_2 = 0 \Rightarrow x_1 = -x_2$$

$0=0$ es infinitas soluciones, cualquier vector

$$x_1 = -x_2 \text{ cumple } v_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$\text{la norma de } \|v_2\| = 1 \Rightarrow 1 = \sqrt{x_1^2 + x_2^2} \Rightarrow 1 = x_1^2 + (-x_1)^2$$

$$x_1 = 0.707 \quad x_2 = -0.707$$

$$\lambda_1 = 1.6, \text{ representa } \lambda_1 / \sum_{i=1}^k \lambda_i, \frac{1.6}{2} = 80\% \text{ de la varianza}$$

No supervisado, PCA Principal Components Analysis(proyectar)


4) Seleccionar el número de dimensiones, 1D

$$\tilde{X} = X V_1 V_1^T + X V_2 V_2^T \text{ or } X V V^T \text{ or } Z V^T$$

Utilizando los eigen vectors podemos transformar de 2D \Rightarrow 1D

$$Z = \begin{bmatrix} 0.63 & -0.63 \\ -0.63 & 0.63 \\ 1.26 & 1.26 \\ -1.26 & -1.26 \end{bmatrix} \cdot \begin{bmatrix} 0.707 \\ 0.707 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 1.781 \\ -1.781 \end{bmatrix} \text{ Proyección 1D}$$

varianza.



El resultado es la reducción de 2 dimensiones a 1 dimensión. Después podemos devolvernos y notar los errores en la reconstrucción

transformar datos de 1D a 2D, $Z V^T$

$$\tilde{X} = \begin{bmatrix} 0 \\ 0 \\ 1.781 \\ -1.781 \end{bmatrix} \cdot \begin{bmatrix} 0.707 & 0.707 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 1.259 & 1.259 \\ -1.259 & -1.259 \end{bmatrix}$$

Como podemos ver \tilde{X} es muy similar a los datos X

$$\tilde{X} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 1.259 & 1.259 \\ -1.259 & -1.259 \end{bmatrix} \quad X = \begin{bmatrix} 0.63 & -0.63 \\ -0.63 & 0.63 \\ 1.26 & 1.26 \\ -1.26 & -1.26 \end{bmatrix}$$

No supervisado, PCA Principal Components Analysis(Python)

```
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
import pandas as pd
import numpy as np
X = pd.DataFrame([[2,-1],[-2,1],[4,2],[-4,-2]] , columns=["x1","x2"])
print("Estandarizar")
scaler = StandardScaler()
scaler.fit(X)
X_sc = scaler.transform(X)
print("Eigenvalues: \n",X_sc)
print("Entrenar PCA")
pca = PCA(n_components=2)
pca.fit(X_sc)
print("Eigenvalues: \n",pca.explained_variance_)
print("% Varianza explicada: \n",pca.explained_variance_ratio_)
print("% Varianza explicada: \n",pca.explained_variance_ratio_)
print("Proyectar los datos: \n",pca.transform(X_sc))
```

```
Estandarizar
Eigenvalues:
[[ 0.63245553 -0.63245553]
 [-0.63245553  0.63245553]
 [ 1.26491106  1.26491106]
 [-1.26491106 -1.26491106]]
Entrenar PCA
Eigenvalues:
[2.13333333 0.53333333]
% Varianza explicada:
[0.8 0.2]
% Varianza explicada:
[0.8 0.2]
Proyectar los datos:
[[ 1.67871766e-17  8.94427191e-01]
 [-1.67871766e-17 -8.94427191e-01]
 [ 1.78885438e+00  3.35743533e-17]
 [-1.78885438e+00 -3.35743533e-17]]
```

```
pca = PCA(n_components=1)
pca.fit(X_sc)
print("Eigenvalues: \n",pca.explained_variance_)
print("% Varianza explicada: \n",pca.explained_variance_ratio_)
print("% Varianza explicada: \n",pca.explained_variance_ratio_)
print("Proyectar los datos: \n",pca.transform(X_sc))
```

```
Estandarizar
Eigenvalues:
[[ 0.63245553 -0.63245553]
 [-0.63245553  0.63245553]
 [ 1.26491106  1.26491106]
 [-1.26491106 -1.26491106]]
Entrenar PCA
Eigenvalues:
[2.13333333]
% Varianza explicada:
[0.8]
% Varianza explicada:
[0.8]
Proyectar los datos:
[[ 0.          ]
 [ 0.          ]
 [ 1.78885438]
 [-1.78885438]]
```

Utilizar python para calcular la proyección (mismo resultado), algunos eigenvalores pueden diferir por la fórmula de covarianza utilizada (población vs muestra)

No Supervisado, K-means (Clusters)


Cuando no se tiene etiquetas, el clustering puede ayudarnos a entender cómo crear agrupaciones de los datos basados en su similaridad.

$$\sum_{i=0}^n \min_{\mu_j \in C} (||x_i - \mu_j||^2)$$

Parámetro K es el numero grupos que quiero obtener del cluster

Ejemplo: utilizando datos del dataset de automóviles

Autos 2D with PCA and K-means





No supervisado, Dendograma o cluster jerárquico

Proceso de :

- **Inicia:** Cada observación es un cluster de 1 registro.
- **Medir la distancia entre los clusters:** Medir las distancia entre los clusters:
 - Complete: Max intercluster diferencias, por pares
 - Single: Minimal intercluster diferencias, por pares
 - Average: Mean intercluster diferencias,
 - Centroid: Distancia entre los centroides
- **Combinar:** combinar los que tengan menor diferencias
- **Repetir** paso 2 y 3 hasta tener 1 solo grupo

Ejemplo: utilizando ejemplo con 9 registros



No supervisado, Dendograma o cluster jerárquico

Proceso de :

- **Inicia:** Cada observación es un cluster de 1 registro.
- **Medir la distancia entre los clusters:**
 $\{7\}$ con $\{5,8,2,9,1,6,3,4\}$
 $\{6\}$ con $\{1,4,2,3,8,5,9\}$
- **Combinar:** combinar los que tengan menor diferencias
 $\{7,5\}$ 5,8,2,9,1,6,3,4
- **Repetir** paso 2 y 3 hasta tener 1 solo grupo

Ejemplo: utilizando ejemplo con 9 registros

